

Modelagem preditiva do IBOVESPA com Machine Learning



Fábio Aluizio Paulino

Filipe Hideki Kwang

Rodolfo Henrique Gonçalo Conceição

Modelagem preditiva do IBOVESPA com Machine Learning

Pós Tech FIAP

Data Analytics

11DTAT

Janeiro de 2026

Primeiros passos e preparação dos dados


Começamos o desafio do Tech Challenge 2 com a coleta dos **dados do IBOVESPA**. Os dados históricos foram extraídos da plataforma especializada no mercado financeiro Investing, disponível no endereço <https://br.investing.com/indices/bovespa-historical-data>. A base de dados original fornecida pelo site apresentava os seguintes campos: "Data", "Último", "Abertura", "Máxima", "Mínima", "Vol." e "Var%".

No processo de preparação e limpeza dos dados, foi tomada a decisão estratégica de excluir as colunas "Vol." (Volume) e "Var%" (Variação Percentual). Esta escolha se justifica pelo fato de que, para a proposta específica de modelagem preditiva a ser implementada neste projeto, o volume de negociações e a variação diária não apresentavam uma correlação direta ou uma relevância estatística imediata que justificasse sua inclusão, visando a simplificação do modelo e a focagem nos indicadores de preço.

Em seguida, para facilitar o manuseio e o entendimento dos dados no ambiente de programação e análise, os nomes das colunas restantes foram padronizados e transformados para a nomenclatura universalmente aceita em análises de séries temporais de mercado:

- 'Data' foi renomeada para 'date' e foi transformado no índice do dataframe;
- 'Último' (preço de fechamento) foi renomeada para 'close';
- 'Abertura' foi renomeada para 'open';
- 'Máxima' foi renomeada para 'high';
- 'Mínima' foi renomeada para 'low'.

Com os dados devidamente tratados e estruturados, uma análise exploratória inicial foi realizada. Ao plotar os dados de preço de fechamento ('close') do IBOVESPA ao longo dos trinta anos, foi possível identificar, a primeiro momento, um padrão de tendência de alta consistente na série histórica anual. Esta constatação preliminar é crucial, pois sugere a natureza não estacionária da série e a necessidade de técnicas de modelagem que sejam capazes de capturar e projetar essa tendência de longo prazo, como modelos de séries temporais avançados ou técnicas de *Machine Learning* adequadas para dados sequenciais.




Para aprimorar a capacidade preditiva do modelo no que diz respeito ao fechamento do IBOVESPA (alta ou baixa), e em consonância com o escopo e objetivos do projeto, foi implementada uma estratégia de enriquecimento do conjunto de dados.

Esta consistiu na criação de features adicionais que representam os valores de negociação do dia anterior (d-1). Especificamente, foram introduzidas as seguintes variáveis: **open_d-1** (abertura do dia anterior), **close_d-1** (fechamento do dia anterior), **high_d-1** (máxima do dia anterior) e **low_d-1** (mínima do dia anterior).

A inclusão desses **dados defasados** (ou *lagged features*) é crucial em modelos de séries temporais, pois fornece ao algoritmo de Machine Learning informações contextuais importantes sobre o comportamento recente do mercado. O preço de fechamento do dia anterior, por exemplo, é um dos indicadores mais relevantes para a direção do preço no dia seguinte, funcionando como um ponto de referência psicológica e técnica para os investidores. Ao incorporar esses valores (d-1), garantimos que o modelo tenha dados suficientes para capturar a dependência temporal e as dinâmicas de inércia do mercado, elevando a precisão da previsão do fechamento.

Em seguida, para dar continuidade à análise fundamental e visualização da série temporal do IBOVESPA, e antes de prosseguir com a aplicação dos modelos preditivos, foi realizada a **decomposição estatística** da variável de fechamento. Este processo visa desmembrar a série histórica do preço de fechamento nos seus componentes básicos: tendência (o movimento de longo prazo), sazonalidade (padrões recorrentes em intervalos fixos, se houver) e resíduo/ruído (as flutuações aleatórias não explicadas pela tendência ou sazonalidade). A decomposição fornece uma base sólida para a compreensão da estrutura dos dados ao longo do período analisado, auxiliando na escolha e calibração mais eficaz dos modelos de previsão a serem utilizados.



Para iniciar a análise de predição, o modelo utilizou um conjunto de **variáveis de entrada (preditoras ou features)** composto por: o preço de abertura no dia atual (open), o preço de abertura do dia anterior (open d-1), o preço de fechamento do dia anterior (close d-1), o preço máximo do dia anterior (high d-1) e o preço mínimo do dia anterior (low d-1).

O **alvo (variável dependente ou target)** definido para o modelo de regressão foi o **preço de fechamento do dia atual (close)**. Essa escolha de features baseia-se na premissa de que os valores históricos recentes e a volatilidade do dia anterior são relevantes para prever o preço de fechamento no dia atual.

Seleção de Modelos

Com o objetivo de identificar o modelo de regressão mais adequado para a predição do Índice IBOVESPA, foi realizada uma estratégia de testes simultâneos com uma ampla variedade de algoritmos de Machine Learning. Esta abordagem multifacetada, baseada em estudos de caso do livro *Blueprints de Aprendizado de Máquina e Ciência de Dados para Finanças* (Tatsat, Puri & Lookabaugh, publicado pela Editora Alta Books) permitiu uma avaliação comparativa abrangente do desempenho de diferentes tipos de modelos em relação aos dados de séries temporais.

Os modelos de regressão testados incluem:


1. **SVR (Support Vector Regression):** Um modelo baseado em *Support Vector Machines* adaptado para regressão, robusto a *outliers*.
2. **DecisionTreeRegressor:** Um modelo não paramétrico que constrói uma árvore de decisão para fazer previsões.
3. **KNeighborsRegressor:** Um algoritmo baseado em instâncias que utiliza a média dos k vizinhos mais próximos para a predição.
4. **ElasticNet:** Uma regressão linear regularizada que combina as penalidades L1 (Lasso) e L2 (Ridge), sendo útil para lidar com multicolinearidade e grande

número de *features*.

5. **Lasso**: Regressão linear com penalidade L1, que pode levar à esparsidade do modelo (seleção automática de variáveis).
6. **LinearRegression**: O modelo de regressão linear mais básico e fundamental.
7. **MLPRegressor (Multi-layer Perceptron Regressor)**: Uma rede neural artificial feedforward, capaz de capturar relações não-lineares complexas.
8. **AdaBoostRegressor (Adaptive Boosting Regressor)**: Um método de *ensemble* que combina vários preditores fracos para criar um preditor forte.
9. **GradientBoostingRegressor**: Outro método de *ensemble* que constrói o modelo de forma sequencial, corrigindo os erros dos modelos anteriores.
10. **RandomForestRegressor**: Um método de *ensemble* baseado em árvores de decisão que utiliza a média das previsões de múltiplas árvores.
11. **ExtraTreesRegressor (Extremely Randomized Trees Regressor)**: Semelhante ao *Random Forest*, mas com maior aleatoriedade na divisão dos nós, visando reduzir a variância.

Essa decisão estratégica de testar simultaneamente múltiplos algoritmos foi motivada pela necessidade inicial de realizar uma "triagem" ou "limpa". O objetivo primário era identificar e descartar os algoritmos/modelos que apresentassem os maiores erros de predição ou as maiores discrepâncias em relação aos dados observados. Conforme os resultados e as discrepâncias visualizadas nos testes plotados, seria possível refinar a escolha para os modelos de melhor desempenho e, subsequentemente, dedicar mais esforço à sua otimização (ajuste de hiperparâmetros).

Comparação de algoritmos: resultado Kfold





Já na primeira iteração do algoritmo **K-fold** para os modelos preditivos, uma análise preliminar revelou um desempenho notoriamente insatisfatório por parte do modelo **Support Vector Regression (SVR)**. Especificamente, as métricas de avaliação e a capacidade preditiva do SVR se mostraram significativamente abaixo dos outros modelos em consideração.

Este desempenho inicial fraco, evidenciado nos primeiros ciclos de validação cruzada, nos levou a questionar a adequação do SVR para a modelagem preditiva do Índice IBOVESPA, dada a complexidade e a volatilidade dos dados de séries temporais financeiras. Em vez de dispendar tempo e recursos computacionais consideráveis na otimização e ajuste de hiperparâmetros de um modelo que demonstrou tal deficiência inicial, optamos por uma abordagem pragmática.

Assim, foi tomada a decisão imediata de **descartar o modelo SVR** do conjunto de modelos a serem avaliados e comparados na fase subsequente de testes e análise. Esta exclusão permitiu que o foco do estudo fosse direcionado para os modelos que apresentaram resultados iniciais mais promissores, garantindo uma alocação mais eficiente dos recursos do projeto e acelerando o processo de identificação da arquitetura preditiva mais robusta.

Comparação de algoritmos: resultado Kfold (sem SVR)





A análise comparativa do desempenho dos modelos de Machine Learning testados revelou padrões distintos em relação à capacidade de generalização e ao equilíbrio entre viés e variância. Os **Modelos Lineares**, englobando Regressão Linear (LR), LASSO e ElasticNet, destacaram-se significativamente ao apresentar consistentemente os **menores Erros Quadráticos Médios (MSE)** no conjunto de teste. Esta performance não apenas indica uma precisão superior na previsão para dados não vistos, mas também foi validada pela robusta consistência observada durante a validação cruzada K-fold. Este baixo erro de teste e alta consistência são fortes indicadores de uma boa generalização e de um equilíbrio viés-variância ideal, sugerindo que estes modelos capturaram a estrutura fundamental dos dados sem se prenderem excessivamente ao ruído do conjunto de treino.

Em contrapartida, modelos como o **K-Vizinhos Mais Próximos (KNN)** e **toda a família de Modelos Baseados em Árvores** (incluindo Árvores de Classificação e Regressão - CART, Florestas Aleatórias de Regressão - RFR, Árvores Extremamente Aleatórias - ETR, *Gradient Boosting Regressor* - GBR e *AdaBoost Regressor* - ABR) exibiram um problema marcante de **overfitting** (sobreajuste).

Esta condição foi diagnosticada pela grande disparidade entre um erro de treino extremamente baixo (indicativo de que o modelo memorizou os dados de treino) e um erro de teste significativamente elevado, acompanhado por uma alta variabilidade nos resultados. Essa alta variância sugere que esses modelos são excessivamente sensíveis a pequenas flutuações nos dados de treino, comprometendo seriamente sua utilidade preditiva em novos dados.

O modelo de rede neural **Perceptron Multicamadas (MLP)** demonstrou um desempenho intermediário e mais estável. Embora não tenha alcançado a performance superior dos modelos lineares, ele superou a maioria dos modelos

baseados em árvores em termos de erro de teste e consistência, posicionando-se como uma alternativa viável que poderia ser explorada com maior otimização de hiperparâmetros ou arquitetura.

Em síntese, a conclusão primordial é que os modelos lineares se estabelecem como a abordagem mais promissora e eficiente para este conjunto de dados, demandando pouca ou nenhuma otimização adicional. Os modelos restantes (com a exceção explícita do SVR) demonstram potencial, mas exigiriam um processo rigoroso e extensivo de otimização de hiperparâmetros e, possivelmente, a aplicação de técnicas de regularização ou *ensemble* mais robustas para atenuar o forte *overfitting* observado e melhorar sua capacidade de generalização.

Acrescentando modelos de séries temporais


A seguir, incluímos os modelos de séries temporais **SARIMAX e LSTM** na nossa análise comparativa para a modelagem preditiva do Índice IBOVESPA. No entanto, o modelo **LSTM apresentou uma performance inicialmente desastrosa**. Já na primeira iteração do treinamento, observamos que os erros quadráticos médios (RMSE) e os erros absolutos médios (MAE), tanto no conjunto de treino quanto no de teste, estavam muito acima dos demais modelos testados, como o SARIMAX e outros modelos de referência.

Essa performance inesperada levou-nos a questionar a adequação da abordagem inicial. Suspeitamos que a natureza volátil e não estacionária dos preços brutos do IBOVESPA, com variações em magnitude que poderiam desestabilizar o gradiente da rede, estava a prejudicar seriamente o aprendizado do LSTM.

Por isso, optamos por realizar um novo teste, aplicando uma **transformação logarítmica aos dados de preço**. Esta técnica é comum em finanças para estabilizar a variância e aproximar a distribuição dos retornos à normalidade. A utilização dos preços na escala logarítmica levou a uma **melhora substancial do seu resultado**. Os novos erros de treino e teste do LSTM caíram significativamente, aproximando-se dos valores observados nos modelos de melhor desempenho.


Este ajuste metodológico provou ser crucial para resgatar o potencial do modelo LSTM e permitir uma comparação mais justa e robusta com os outros modelos em análise, conforme será detalhado e visualizado no gráfico subsequente que compara as métricas de erro de todos os modelos ajustados.

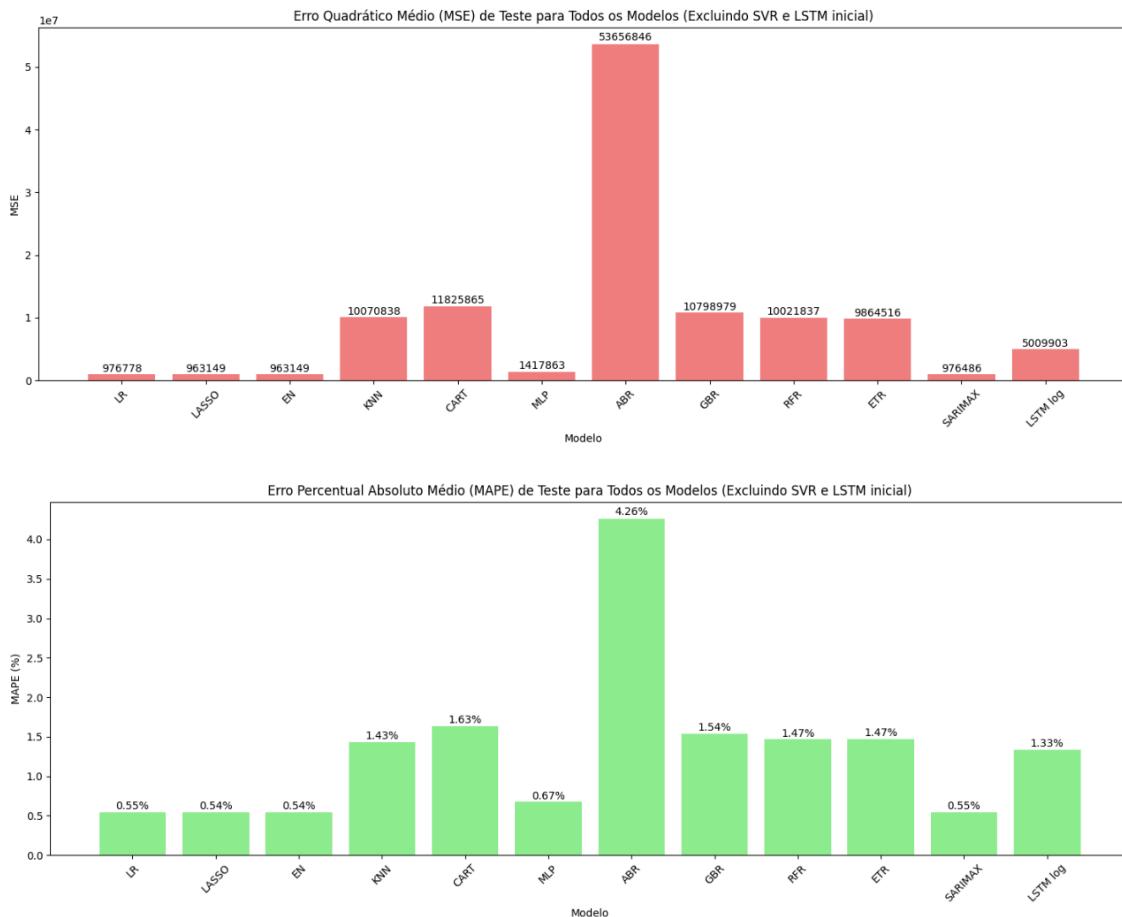
Comparação de algoritmos (sem SVR e LSTM inicial)



Análises iniciais

Para termos uma base maior de comparação dos modelos, aumentamos a análise utilizando as métricas **MAE (erro médio absoluto)**, **MSE (erro quadrático médio)** e **MAPE (erro percentual absoluto médio)** para verificar o desempenho de cada sistema na previsão de preço dentro do conjunto de teste, obtendo os resultados a seguir:





A análise visual do gráfico de previsões (excluindo SVR e LSTM inicial) em comparação com os valores reais de fechamento do Ibovespa no conjunto de teste logo abaixo revelou as seguintes observações sobre a aderência dos modelos:

Melhor Aderência (Previsões Consistentes):

- **Modelos Lineares (LR, LASSO, ElasticNet) e SARIMAX:** Estes modelos demonstraram o melhor desempenho visual, seguindo de perto a linha dos valores reais. Suas previsões acompanharam consistentemente tanto a magnitude quanto a direção dos movimentos do mercado, sugerindo uma boa capacidade de generalização e baixa variância.


Desempenho Razoável (Boa Captura de Tendência):

- **MLP (Rede Neural Multicamadas):** O MLP conseguiu seguir a tendência geral do mercado de forma satisfatória. Embora tenha apresentado desvios de magnitude ligeiramente maiores em alguns pontos, sua habilidade em capturar a direção do mercado é um ponto visualmente notável.

Pior Aderência e Alta Volatilidade (Risco de Overfitting):


- **Modelos Baseados em Árvores (CART, RFR, ETR, GBR, ABR) e KNN:** Estes modelos exibiram maior oscilação e, em certos casos, desvios significativos da linha real. Essa instabilidade visual pode indicar um potencial *overfitting* ou uma menor capacidade de generalização para este conjunto de

dados, resultando em previsões que não mantiveram uma proximidade constante com os valores observados.








Aproveitamos esta fase para conduzir a primeira avaliação completa da **acurácia direcional** de todos os modelos preditivos desenvolvidos. Além de ser o foco do desafio, esta métrica é fundamental, pois mede a capacidade dos modelos de **prever corretamente a direção (alta ou baixa)** do Índice IBOVESPA no período subsequente. No entanto, é importante ressaltar que, nestes testes iniciais de validação e calibração, os resultados de acurácia direcional ainda não atingiram a meta ambiciosa estabelecida de 75%.

Este patamar representa o desempenho mínimo desejado para considerarmos os modelos robustos e com potencial de aplicação prática. A identificação desta lacuna inicial direciona nossos esforços futuros para a otimização dos parâmetros, a exploração de variáveis preditivas adicionais e o refinamento das arquiteturas dos modelos para que possamos convergir para o resultado desejado.



Nos gráficos a seguir, realizamos uma plotagem individual dos cinco modelos com melhor desempenho. O objetivo foi **analisar, durante os 30 dias de teste, o desempenho de cada modelo em acertar ou errar a direção do índice**. Os resultados indicaram que os modelos **LASSO, EM, SARIMAX e LR acertaram 18 das 30 "previsões"**. O modelo **MLP apresentou o melhor desempenho, com 20 acertos em 30, o que corresponde a 66,67% dos dados**.





Enriquecendo os dados com feature engineering

Com o objetivo de capturar diversas nuances do comportamento do preço do Ibovespa para aprimorar a previsão, uma série de indicadores técnicos foi incorporada ao *dataframe* com o uso da biblioteca *pandas*. Esses indicadores fornecem diferentes perspectivas sobre o mercado:

Indicadores Adicionados:


- **RSI (Relative Strength Index - RSI_14_d-1):** Oscilador de momentum essencial para identificar condições de sobrecompra e sobrevenda, mensurando a velocidade e a variação dos preços.
- **Distância até a EMA (distance_to_ema9_d-1):** Calcula a diferença entre o preço de fechamento e uma Média Móvel Exponencial de 9 períodos, sinalizando a força da tendência e potenciais reversões.
- **Percentual da Largura das Bandas de Bollinger (percent_bandwidth_d-1):** Quantifica a amplitude das Bandas de Bollinger em relação ao seu centro, sendo útil para identificar períodos de alta ou baixa volatilidade.
- **ROC (Rate of Change - ROC_10) e Momentum (MOM_10):** Indicadores similares que medem a taxa percentual (ROC) ou a magnitude (MOM) da variação do preço de fechamento, ambos apontando para o *momentum* do ativo.
- **AO (Awesome Oscillator - AO_5_34):** Oscilador de momentum que avalia a relação entre médias móveis rápidas e lentas do ponto médio das barras de preço.
- **MACD (Moving Average Convergence Divergence - MACD_12_26_9, MACDh_12_26_9, MACDs_12_26_9):** Exibe a relação entre duas médias móveis. O Histograma (MACDh) é a diferença entre a linha MACD e a linha de sinal (MACDs), indicando as mudanças no *momentum*.

Resultados da Análise de Correlação:




A análise de correlação entre estas novas features e os preços existentes (abertura, fechamento, máxima, mínima, e suas versões defasadas *_d-1*) revelou padrões importantes:

1. **Alta Correlação entre Preços:** Conforme esperado, há uma correlação extremamente alta (próxima de 1) entre as colunas de preço e suas versões defasadas, por serem medidas intrinsecamente relacionadas ao mesmo ativo.
2. **Correlação entre Indicadores de Momentum:** Indicadores que medem o *momentum* de maneira semelhante, como ROC_10 e MOM_10 (0.99), e os próprios componentes do MACD (MACD, MACDh, MACDs), demonstram forte correlação mútua, dada a derivação das mesmas médias móveis.
3. **Correlação Moderada/Alta com o Preço:** Muitos indicadores (RSI, distância da EMA, ROC, Momentum e MACD) apresentam uma correlação que varia de moderada a alta com as *features* de preço, o que é esperado, pois são calculados diretamente a partir destes.
4. **Diversidade de Informação (Baixa Redundância):** Indicadores como o *percent_bandwidth_d-1* se destacam por exibirem correlações mais baixas com as demais *features*. Este resultado é positivo, pois sugere que eles estão

introduzindo informações novas e menos redundantes, principalmente sobre a volatilidade do mercado, o que tem potencial para enriquecer o conjunto de *features* e aumentar o poder preditivo dos modelos.



Com a inclusão dessas novas variáveis ao *dataframe*, iniciamos uma nova etapa de testes, focada nos cinco modelos que obtiveram os resultados mais promissores na rodada anterior.



Com a implementação das novas features, **foi observada uma melhora perceptível na performance dos modelos em relação às três métricas de erro quantitativo analisadas**. Tal redução nos erros indica uma capacidade aprimorada dos modelos em se ajustarem aos dados históricos e em prever os valores do índice IBOVESPA com maior proximidade dos valores reais.


Entretanto, de forma contra-intuitiva, **a métrica de avaliação mais crítica para o objetivo principal do nosso estudo, a acurácia direcional, não apresentou melhorias** em nenhum dos modelos testados quando comparada aos resultados obtidos na rodada de testes anteriores.


Padronização das features de entrada

Diante da persistência deste dilema (modelos com menor erro quantitativo, mas sem ganho na capacidade preditiva de direção), e considerando que a magnitude das *features* de entrada pode influenciar o processo de convergência e a estabilidade dos modelos de *Machine Learning*, **optamos por uma intervenção na fase de pré-processamento de dados.**

Especificamente, decidiu-se realizar um **escalonamento ou padronização das features de entrada (*feature scaling*)**. Para tal, foi empregado o método `StandardScaler` da biblioteca `Scikit-learn` em Python. A expectativa é que esta padronização ajude a mitigar o impacto de *features* com diferentes escalas e variâncias nos algoritmos.

Após a aplicação do *feature scaling*, fizemos uma nova rodada de testes das métricas de erro dos modelos e da acurácia direcional dos mesmos:





Previsões e resultados finais

Apesar do modelo Perceptron Multicamadas (MLP) ter apresentado um desempenho **negativo em comparação com os outros modelos** em relação às métricas de erro, especificamente no que diz respeito à previsão dos preços absolutos do índice IBOVESPA, observou-se uma **melhora notável em sua capacidade de acerto direcional**. Essa melhoria é de suma importância para a tomada de decisão, uma vez que a direção do movimento do mercado é frequentemente mais crítica do que o preço exato.

O modelo MLP **superou o resultado mínimo desejado** para a acurácia direcional. Mais especificamente, atingiu uma **acurácia direcional impressionante de 76,67%**. Esse resultado foi alcançado através de **23 acertos na previsão da direção de movimento do IBOVESPA ao longo do período de 30 dias** estabelecido para os testes.

Isso sugere que, embora o MLP possa não ser o modelo mais robusto para a estimação precisa dos valores de preços, ele demonstrou uma **capacidade significativa de identificar a tendência** do mercado (alta ou baixa) no curto prazo.

Os gráficos subsequentes, aos quais esta seção faz referência, ilustram detalhadamente tanto o desvio de preços observado quanto a performance superior na acurácia direcional, fornecendo uma visão mais completa da dualidade de desempenho do modelo MLP no contexto da modelagem preditiva do índice IBOVESPA.

Gráfico de linhas mostrando a evolução dos pontos de teste e as previsões do modelo MLP ao longo do tempo. O eixo Y representa 'Pontos' (80.000 a 150.000) e o eixo X representa 'Data' (29/09/2025 a 07/11/2025).

Legenda:

- Valores Reais (Teste)
- MLP Predições
- Direção Correta (pontos verdes)
- Direção Incorreta (pontos vermelhos com X)

O gráfico demonstra que as previsões do modelo MLP (seja corretas ou incorretas) permanecem significativamente abaixo dos valores reais observados no conjunto de teste, indicando uma limitação na capacidade do modelo de capturar a magnitude real dos dados.

Gráfico de Linhas: Pontuação no LASSO vs. Data. O gráfico mostra a evolução da pontuação de teste ao longo do tempo, com a linha sólida preta representando os valores reais e a linha tracejada azul representando as previsões do LASSO. Os pontos verdes indicam direções corretas e os pontos vermelhos indicam direções incorretas.

Data	Valores Reais (Teste)	LASSO Predições	Direção Correta	Direção Incorreta
28/09/2025	145500	145500	1	0
01/10/2025	146300	146300	1	0
03/10/2025	144000	144000	1	0
06/10/2025	143500	144200	1	0
08/10/2025	141500	144200	1	0
10/10/2025	142200	141500	1	0
12/10/2025	141000	141500	1	0
14/10/2025	142500	141500	1	0
16/10/2025	143500	142200	1	0
18/10/2025	144500	142200	1	0
20/10/2025	144500	144500	1	0
22/10/2025	145500	144500	1	0
24/10/2025	146000	145500	1	0
26/10/2025	146500	146000	1	0
28/10/2025	147000	146500	1	0
30/10/2025	148500	147000	1	0
01/11/2025	149000	148500	1	0
03/11/2025	150500	149000	1	0
05/11/2025	151000	150500	1	0
07/11/2025	153500	153500	1	0

Gráfico de Linhas: Evolução dos pontos de teste e direção correta/errada.



Legenda:

- Valores Reais (Teste)
- EN Predições
- Direção Correta
- Direção Incorreta

O gráfico mostra a evolução dos pontos de teste (Valores Reais) e a direção correta/errada (EN Predições) ao longo do tempo. O eixo Y representa os pontos (Pontos) e o eixo X representa a data (Data).

Os dados são os seguintes:

Data	Valores Reais (Teste)	EN Predições	Direção Correta	Direção Incorreta
28/09/2025	146000	138000	138000	138000
03/10/2025	144000	138000	138000	138000
08/10/2025	143000	136000	136000	136000
13/10/2025	141000	134000	134000	134000
18/10/2025	143000	134000	134000	134000
23/10/2025	145000	136000	136000	136000
28/10/2025	146000	138000	138000	138000
02/11/2025	148000	140000	140000	140000
07/11/2025	150000	142000	142000	142000



Prevendo o fechamento do dia seguinte sem abertura de D

Apesar de termos alcançado a acurácia desejada com o modelo anterior, decidimos, por razões didáticas e como um desafio adicional, buscar um resultado semelhante utilizando um modelo MLP sem incluir os dados de abertura (open) do dia (D). O objetivo era transformar um modelo de alta performance para negociação *intraday* em um modelo que oferecesse um resultado satisfatório na previsão do dia subsequente.

Após a remoção da coluna 'open' do conjunto de *features* e o re-treinamento do modelo MLP com os dados escalados, os resultados observados foram:

Métricas de Treino e Teste (Magnitude):


- **MAE (Erro Médio Absoluto):** No treino, o MAE foi de aproximadamente

34.612, mas no teste, aumentou drasticamente para cerca de 77.267. Este valor é consideravelmente superior ao MAE do MLP com a coluna 'open' (que era de aproximadamente 62.732 no teste).

- **MSE (Erro Quadrático Médio):** O MSE de treino foi de cerca de 1,67 bilhões, saltando para 5,98 bilhões no teste. Houve uma piora notável em comparação ao MSE do MLP com a coluna 'open' (que era de aproximadamente 3,94 bilhões no teste).
- **MAPE (Erro Percentual Absoluto Médio):** O MAPE de treino foi de 69,89% e, no teste, de 53,00%. Este resultado também indica uma deterioração em relação ao MAPE do MLP que incluía o 'open' (que era de 43,04% no teste).

Acurácia Direcional:

A acurácia direcional para o modelo MLP sem a *feature* 'open' foi de **70,00%** (21 acertos em 30). Embora este valor seja inferior aos 76,67% alcançados pelo MLP original com a coluna 'open', é um resultado ainda assim interessante, pois o modelo conseguiu manter uma acurácia direcional próxima do desejado, mesmo sem a inclusão dessa *feature* fundamental.




Otimização do modelo sem a feature 'open' via Grid Search

Para aprimorar o desempenho do modelo Multilayer Perceptron treinado sem a coluna 'open', foi aplicado um processo de *Grid Search* com o objetivo de otimizar seus hiperparâmetros.

Resultados do Grid Search:

- **Melhores Hiperparâmetros:** O *Grid Search* identificou a seguinte configuração ideal para o `MLPRegressor`: `{'activation': 'relu', 'alpha': 0.01, 'hidden_layer_sizes': (50,), 'learning_rate_init': 0.01, 'solver': 'adam'}`.
- **Métricas de Desempenho:**
 - a. **MAE (Erro Absoluto Médio)**
 - i. Desempenho no Treinamento: 660.26

- ii. Desempenho no Teste: 910.74
- b. **MSE (Erro Quadrático Médio)**
 - i. Desempenho no Treinamento: 949.045,69
 - ii. Desempenho no Teste: 1.193.271,96
- c. **MAPE (Erro Percentual Absoluto Médio)**
 - i. Desempenho no Treinamento: 1,58 %
 - ii. Desempenho no Teste: 0,62 %
- **Acurácia Direcional:** O modelo alcançou uma acurácia direcional de **73.33%** (22 acertos em 30) no conjunto de teste (gráfico abaixo).



A aplicação do *Grid Search* para otimização de hiperparâmetros resultou em uma **melhoria dramática** no desempenho preditivo do modelo. **Este ajuste fino demonstrou a criticidade da engenharia de parâmetros**, elevando o resultado do modelo em todas as métricas analisadas.

No que tange à **previsão de valor**, as métricas de erro melhoraram substancialmente. O **Erro Médio Absoluto (MAE) de Teste** foi **reduzido de impressionantes 77.267 para meros 910**, o que representa uma **precisão quase 85 vezes superior**. O **Erro Quadrático Médio (MSE)** também apresentou uma queda **drástica**, indicando uma **eliminação significativa de desvios grandes e penalizando severamente os outliers**.

O avanço mais notável foi observado na redução do **Erro Percentual Absoluto Médio (MAPE): o valor despencou de 53,00% para 0,62%**. Essa melhoria de mais de 52 pontos percentuais transforma o modelo, movendo-o de um desempenho inaceitável para uma margem de erro percentual inferior a 1% no período de teste analisado.

Além da precisão de valor, a otimização também potencializou a **acurácia direcional** da previsão. O modelo otimizado alcançou **73,33%** de acerto na direção do movimento, um aumento de 3,33 pontos percentuais em relação ao modelo original (70,00%). Este resultado, embora numericamente modesto, é crucial em ambientes voláteis, aproximando-se da meta de excelência de 75% e indicando que o modelo é

capaz de identificar sinais que definem a tendência diária com maior clareza.

Conclusões finais

A análise da modelagem preditiva do Índice IBOVESPA revelou que a escolha do modelo ideal está diretamente ligada ao objetivo da previsão. Para a **previsão da magnitude (Preço)**, modelos lineares (Regressão Linear, LASSO, ElasticNet) e o SARIMAX demonstraram superioridade consistente. Eles apresentaram os menores erros nas métricas MAE, MSE e MAPE em todas as etapas, sinalizando precisão na previsão do valor exato do preço de fechamento.

Já na **previsão da direção do mercado (Tendência)**, o Perceptron Multicamadas (MLP) se destacou. Com a aplicação de Engenharia de Features e o escalonamento das variáveis, o MLP atingiu uma acurácia direcional de 76,67% ao usar o valor de abertura de mercado, e de 73,33% sem essa informação. Mesmo removendo a *feature* 'open', a otimização por *Grid Search* elevou a acurácia direcional do MLP para os supracitados 73%, confirmando-o como a opção mais promissora para estratégias que dependem da identificação correta da direção do movimento do mercado.

O sucesso dos modelos sublinha a importância de duas fases cruciais no pré-processamento de dados financeiros: a **engenharia de features**, fundamental para extrair informações preditivas do mercado, e o **pré-processamento adequado (feature scaling)**, essencial para maximizar a performance de modelos mais complexos, como as redes neurais. Em resumo, modelos lineares e SARIMAX são preferíveis para a precisão do valor de fechamento, enquanto o MLP é a escolha para a acurácia direcional.